

LM: Kategoriale Eingangsgrößen

Kolloquium für Statistik

Departement of Health Professions
Bern University of Applied Sciences

4. Oktober 2023

Zwei kategorielle Eingangsgrößen

- **Zwei** kategorielle Eingangsgrößen, einen Faktor A mit I Kategorien und einen Faktor B mit J Kategorien
- $I \times J$ Stichproben S_{ij} mit Grösse n_{ij} und $n = \sum_{i,j} n_{ij}$.

| | | Faktor B | | | | | |
|----------|----------|----------|----------|---------|----------|---------|----------|
| | | B_1 | B_2 | \dots | B_j | \dots | B_J |
| Faktor A | A_1 | S_{11} | S_{12} | \dots | S_{1j} | \dots | S_{1J} |
| | A_2 | S_{21} | S_{22} | \dots | S_{2j} | \dots | S_{2J} |
| | \vdots | | | | | | \vdots |
| | A_i | | | \dots | S_{ij} | \dots | S_{iJ} |
| | \vdots | | | | | | \vdots |
| | A_I | S_{I1} | S_{I2} | \dots | S_{Ij} | \dots | S_{IJ} |
| | | | | | | | |

- Klassisch nennt man ein solches Design eine **zweifaktorielle** Varianzanalyse.

Means-Parameterisierung

- Die abhängige Variable Y_{ij} setzt sich zusammen aus dem linearen Prädiktor μ_{ij} und einem Fehler ϵ_{ijk} .
- Die μ_{ij} , die $I \times J$ Erwartungswerte sind dann die Parameter in der **Means**-Parameterisierung,

$$\boxed{Y_{ijk} = \mu_{ij} + \epsilon_{ijk}} \quad i = 1, \dots, I, j = 1, \dots, J, k = 1, \dots, n_{ij}$$

Effekt-Parameterisierung

Für die **Effekt**-Parameterisierung ersetzen wir die μ_{ij} durch die Summe aus

- Gesamtmittel μ
- Haupteffekte von A , α_i
- Haupteffekte von B , β_j
- Interaktionseffekte $(\alpha\beta)_{ij}$

Das Modell schreiben wir dann

$$Y_{ijk} = \underbrace{\mu + \alpha_i + \beta_j + (\alpha\beta)_{ij}}_{\mu_{ij}} + \epsilon_{ijk}, \quad i = 1, \dots, I, j = 1, \dots, J, k = 1, \dots, n_{ij}$$

Anzahl Parameter

- Das Modell hat $1 + I + J + (IJ)$ Parameter, also mehr Parameter als erlaubt.
- Modell identifizierbar machen, z.B. mit den **sum-to-zero**-Bedingungen:
 - ▶ $\sum_i \alpha_i = 0$
 - ▶ $\sum_j \beta_j = 0$
 - ▶ $\sum_i (\alpha\beta)_{ij} = 0$ für alle j
 - ▶ $\sum_j (\alpha\beta)_{ij} = 0$ für alle i
- Durch die Zusatzbedingungen haben wir dann
 $1 + (I - 1) + (J - 1) + (I - 1)(J - 1) = I \times J$ Parameter.

Effekt-Parameterisierung in R

In R ist standardmässig nicht die **sum-to-zero** Parameterisierung eingestellt, sondern die **Referenzgruppe**-Parameterisierung:

- $\alpha_1 = 0$
- $\beta_1 = 0$
- $(\alpha\beta)_{1j} = 0$ für alle j
- $(\alpha\beta)_{i1} = 0$ für alle i

Prinzip der Marginalität

- Die Faktoren A und B haben einen Interaktionseffekt, wenn die erwartete Veränderung in der Zielgrösse bei einer Veränderung der Stufe auf dem Faktor A von der Stufe des Faktors B abhängt, und umgekehrt.
- Wenn jede Veränderung der Stufe des Faktors A über alle Stufen vom Faktor B konstant ist, dann haben die beiden Faktoren keinen Interaktionseffekt, sie agieren **additiv**.
- Die Haupteffekte sind dann wohldefiniert und diese zu testen macht Sinn.

Prinzip der Marginalität

- Das Testen von Haupteffekten in Gegenwart von Interaktionseffekten verletzt das **Prinzip der Marginalität**.
- Es ist gemäss diesem Prinzip falsch, Haupteffekte zu interpretieren in der Gegenwart von Interaktionseffekten, oder Haupteffekte aus einem Modell zu entfernen, wenn Interaktionseffekte signifikant sind.

Prinzip der Marginalität*

- In R `anova(mod)` sind standardmässig “Type I Sum of Squares” eingestellt (sequentielle Tests!)
 - ▶ $SS(A)$ for factor A
 - ▶ $SS(A, B) - SS(A)$ for factor B
 - ▶ $SS(AB, A, B) - SS(A, B)$ for interaction AB
- “Type III Sum of Squares” (`car::Anova(mod, type=3)`) verletzen z.T. standardmässig das Prinzip.
 - ▶ $SS(A, B, AB) - SS(B, AB)$ for factor A
 - ▶ $SS(A, B, AB) - SS(A, AB)$ for factor B
 - ▶ Für Type III Sum of Squares: Setze **sum-to-zero** für coding matrix: `options(contrasts=c("contr.sum", "contr.poly"))`, sonst wird Unsinn berechnet!
- Bei balancierten Daten geben beide SS dasselbe Resultat.

Beispiel: Simulation Daten aus einem 3×2 zweifaktoriellen Design.*

```

set.seed(22)
nage <- 3  ## Anzahl Kategorien Altersgruppe
ntherapy <- 2  ## Anzahl Kategorien Therapieart
n <- 200  ## Totale Sample Size
age <- factor(sample(c("child", "young", "old"), size = n, replace = TRUE, prob = c(1, 2, 3)), levels = c("child", "young", "old"))
therapy <- factor(sample(c("Ctrl", "Trt"), size = n, replace = TRUE))
beta1 <- 40  ## Referenz
betaAge <- c(10, 20)  ## betaAge2 und betaAge3
betaTr <- c(10)  ## betaTreat
alphabeta <- c(-0, 0)  ## youngTrt und oldTrt, Interaktionseffekte=0
parameter <- c(beta1, betaAge, betaTr, alphabeta)  ## Wahrer Parametervektor
sigma <- 12  ## Noise SD
epsilon <- rnorm(n, 0, sigma)  ## Fehler
X <- model.matrix(~age * therapy)  ## Design-Matrix
response <- as.numeric(X %*% parameter + epsilon)  ## Y=Xbeta+epsilon, Daten ziehen aus Modell
d.cat2 <- data.frame(response, age, therapy)

```

Daten

Wir haben nun einen Datensatz `d.cat2` mit $n = 200$ Beobachtungen auf den Faktoren `age` (dreiwertig) und `therapy` (zweiwertig.)

```
str(d.cat2)
```

```
## 'data.frame': 200 obs. of  3 variables:
##  $ response: num  78.5 45.6 11.1 51.5 20.6 ...
##  $ age      : Factor w/ 3 levels "child","young",...: 3 3 1 2 1 2 2 2 3 3 ...
##  $ therapy  : Factor w/ 2 levels "Ctrl","Trt": 2 2 1 2 1 2 2 2 2 2 ...
```

```
head(d.cat2)
```

```
##   response age therapy
## 1    78.5  old    Trt
## 2    45.6  old    Trt
## 3    11.1 child  Ctrl
## 4    51.5 young  Trt
## 5    20.6 child  Ctrl
## 6    43.4 young  Trt
```

Ziel

- Wir wollen den Effekt von `therapy` auf die Zielgröße quantifizieren
- und für `age` kontrollieren, wenn nötig.

Beschreiben

- Tabellarisch: `table()`, `xtabs()`, `by()`, `aggregate()`, `tapply()`
- Design

```
addmargins(xtabs(~therapy + age))  
##           age  
## therapy child young old Sum  
##   Ctrl    20    25  54  99  
##   Trt     10    34  57 101  
##   Sum     30    59 111 200
```

- Graphisch: `interaction.plot()` (Abbildung 1).
- Die Altersgruppen innerhalb der Treatmentgruppen sind nicht gleich gross.
- Die graphische Darstellung deutet auf keinen Interaktionseffekt hin.

Beschreiben

```
interaction.plot(x.factor = age, trace.factor = therapy, response = response, trace.label = "treatment", xlab = "age group", ylab = "r
```




Abbildung: Beobachtete Durchschnitte bezüglich Faktoren age und therapy.

Beschreiben

Wir beschreiben die Daten pro Gruppe auf therapy und dann pro Kombination auf therapy und age

```
psych::describeBy(response, list(therapy), mat = TRUE)
```

```
##      item group1 vars   n mean   sd median trimmed  mad min max range  skew kurtosis  se
## X11      1  Ctrl      1  99 53.9 16.3   54.4   54.9 15.6 -4.0 99.7 103.7 -0.617   1.386 1.64
## X12      2   Trt      1 101 63.0 14.3   64.2   63.4 15.8 21.6 93.3  71.6 -0.326  -0.273 1.43
```

```
## by(response,therapy,psych::describe) ##Alternative, weniger kompakt
```

```
psych::describeBy(response, list(therapy, age), mat = TRUE)
```

```
##      item group1 group2 vars   n mean   sd median trimmed  mad min max range  skew kurtosis  se
## X11      1  Ctrl  child      1  20 34.9 16.5   38.0   36.3 16.4 -4.0 56.6  60.6 -0.6681  -0.584 3.69
## X12      2   Trt  child      1  10 41.2 11.8   44.4   41.5 13.7 21.6 58.4  36.8 -0.1773  -1.375 3.72
## X13      3  Ctrl  young      1  25 52.1 11.7   50.9   51.9 15.2 34.1 71.6  37.5  0.2074  -1.326 2.33
## X14      4   Trt  young      1  34 58.7 12.4   55.2   58.3 13.9 40.9 81.5  40.6  0.3188  -1.273 2.12
## X15      5  Ctrl   old      1  54 61.8 11.5   60.9   61.4 11.6 38.6 99.7  61.2  0.5691   0.929 1.56
## X16      6   Trt   old      1  57 69.3 10.9   69.3   69.5 11.2 45.6 93.3  47.7 -0.0521  -0.341 1.44
```

```
## by(response,list(therapy,age),psych::describe) ##Alternative, weniger kompakt
```

Beschreiben

Wir fassen die 6 Durchschnitte $\hat{\mu}_{ij}$ zusammen mit den

- **ungewichteten** Mittel (**Durchschnitte der Durchschnitte**)
- **gewichteten** Mittel (**Durchschnitte in Therapiegruppen** unabhängig von age).

| | child | young | old | unweighted.mean | weighted.mean |
|------|-------|-------|-------|-----------------|---------------|
| Ctrl | 34.89 | 52.13 | 61.78 | 49.60 | 53.91 |
| Trt | 41.20 | 58.74 | 69.35 | 56.43 | 62.99 |

Tabelle: Ungewichtete und Gewichtete Mittel

“Durchschnitte”

- Die beiden Durchschnitte (je für Ctrl und Trt) in den beiden letzten Kolonnen sind nur gleich, wenn das Design balanciert ist, wenn die Altersgruppen gleich gross sind, im Allgemeinen ist das aber – wie hier – nicht der Fall.
- Wenn der Durchschnitt von allen in Ctrl (Trt) die Kontrollgruppe (Treatmentgruppe) repräsentiert (das gewichtete Mittel), dann testen wir den Effekt von therapy mit den Werten auf age in unserer Stichprobe, d.h. wir ignorieren die Variable age.
- Wenn wir die Mittelwerte der Mittelwerte brauchen, dann testen wir den Effekte von therapy **kontrolliert** für age.

Modell anpassen

- Wir passen jetzt ein Modell an mit Haupt- und Interaktionseffekten.
- Die Modell-Formel kann man auf zwei verschiedene Arten eingeben, mit

```
## -A + B + A:B
```

oder mit

```
## -A * B
```

```
modelInt <- lm(response ~ therapy * age, data = d.cat2)
summary(modelInt)
```

```
##
## Call:
## lm(formula = response ~ therapy * age, data = d.cat2)
##
## Residuals:
```

| ## | Min | 1Q | Median | 3Q | Max |
|----|--------|-------|--------|------|-------|
| ## | -38.89 | -8.48 | -0.72 | 8.07 | 37.93 |

```
##
## Coefficients:
```

| ## | Estimate | Std. Error | t value | Pr(> t) |
|------------------------|----------|------------|---------|----------|
| ## (Intercept) | 34.889 | 2.702 | 12.91 | < 2e-16 |
| ## therapyTrt | 6.314 | 4.681 | 1.35 | 0.18 |
| ## ageyoung | 17.245 | 3.626 | 4.76 | 3.8e-06 |
| ## ageold | 26.893 | 3.164 | 8.50 | 5.0e-15 |
| ## therapyTrt:ageyoung | 0.288 | 5.661 | 0.05 | 0.96 |
| ## therapyTrt:ageold | 1.251 | 5.213 | 0.24 | 0.81 |

```
##
## Residual standard error: 12.1 on 194 degrees of freedom
## Multiple R-squared: 0.442, Adjusted R-squared: 0.428
## F-statistic: 30.7 on 5 and 194 DF, p-value: <2e-16
```

Effekt-Parameterisierung in R

child und Ctrl sind die beiden **Referenzkategorien**. Relativ zu diesen sind dann alle Effekte zu interpretieren.

| | | | |
|-----------|------------|------------|------------|
| | child | young | old |
| Control | μ_{11} | μ_{12} | μ_{13} |
| Treatment | μ_{21} | μ_{22} | μ_{23} |

- (Intercept): Geschätzter Erwartungswert für child in Ctrl: $\hat{\mu}_{11}$
- therapyTrt: Geschätzter erwarteter Abstand von Trt zu Ctrl für child: $\hat{\mu}_{21} - \hat{\mu}_{11}$
- ageyoung: Geschätzter erwarteter Abstand von young zu child für Ctrl: $\hat{\mu}_{12} - \hat{\mu}_{11}$
- ageold: Geschätzter erwarteter Abstand von old zu child für Ctrl: $\hat{\mu}_{13} - \hat{\mu}_{11}$
- therapyTrt:ageyoung: Geschätzter erwarteter Unterschied im Unterschied Trt-Ctrl für young versus child: $\hat{\mu}_{22} - \hat{\mu}_{12} - (\hat{\mu}_{21} - \hat{\mu}_{11})$
- therapyTrt:ageold: Geschätzter erwarteter Unterschied im Unterschied Trt-Ctrl für old versus child: $\hat{\mu}_{23} - \hat{\mu}_{13} - (\hat{\mu}_{21} - \hat{\mu}_{11})$

Interaktionen

- Interaktionen sind **Unterschiede von Unterschieden**. Wenn vorhanden, dann haben wir **nicht-parallele** Linien im Interaktionsplot.
- Punktschätzungen für den Therapieeffekt hängen vom Alter ab. Dieser ist
 - ▶ 6.314 für child
 - ▶ $6.314 + 0.288$ für young
 - ▶ $6.314 + 1.251$ für old
- Der Durchschnitt von diesen drei Effekten ist gleich dem Unterschied der ungewichteten Mittel in Tabelle 1.
- Man kann den **Therapieeffekt** (Punktschätzung) auch kurz und knackig mit Indikatorvariablen schreiben:

$$6.314 + 0.288 \times I_{young} + 1.251 \times I_{old}$$

Testen von Hypothesen

Wir passen nun auch ein Modell an ohne den Interaktionseffekt und die beiden Modelle mit nur einer Eingangsgrösse:

```
(modelMain <- update(modelInt, ~. - therapy:age))

##
## Call:
## lm(formula = response ~ therapy + age, data = d.cat2)
##
## Coefficients:
## (Intercept)  therapyTrt    ageyoung    ageold
##          34.62         7.11        17.22        27.39
```

```
(modelTherapy <- update(modelMain, ~. - age))

##
## Call:
## lm(formula = response ~ therapy, data = d.cat2)
##
## Coefficients:
## (Intercept)  therapyTrt
##          53.91         9.08
```

```
(modelAge <- update(modelMain, ~. - therapy))

##
## Call:
## lm(formula = response ~ age, data = d.cat2)
##
## Coefficients:
## (Intercept)    ageyoung    ageold
##          37.0         18.9         28.7
```

Testen vom Interaktionseffekt

Ist der Effekt von therapy abhängig von der Altersgruppe? `anova()` oder `drop1()`.

```
anova(modelMain, modelInt) ## explizit über Modellvergleich
```

```
## Analysis of Variance Table
##
## Model 1: response ~ therapy + age
## Model 2: response ~ therapy * age
##   Res.Df  RSS Df Sum of Sq  F Pr(>F)
## 1      196 28351
## 2      194 28337  2      13.7 0.05  0.95
```

```
anova(modelInt) ## geht auch, da sequentiell und INTERAKTIONSEFFEKT AM SCHLUSS
```

```
## Analysis of Variance Table
##
## Response: response
##           Df Sum Sq Mean Sq F value    Pr(>F)
## therapy      1   4117     4117   28.19 0.0000003
## age          2  18313     9157   62.69 < 2e-16
## therapy:age   2     14        7    0.05    0.95
## Residuals   194  28337     146
```

```
drop1(modelInt, test = "F") ## drop1 respektiert das Prinzip der Marginalität, Haupteffekte werden nicht getestet.
```

```
## Single term deletions
##
## Model:
## response ~ therapy * age
##           Df Sum of Sq  RSS   AIC F value Pr(>F)
## <none>                 28337 1003
## therapy:age  2      13.7 28351  999    0.05  0.95
```

Testen vom Haupteffekt

- Der Interaktionseffekt ist nicht signifikant, d.h. wir können das Modell ohne Interaktion nicht verwerfen.
- Wir können jetzt Hypothesen testen bezüglich den Haupteffekten.
- Wir testen den Effekt von therapy, kontrolliert für age:

```
anova(modelAge, modelMain) ## als Modellvergleich

## Analysis of Variance Table
##
## Model 1: response ~ age
## Model 2: response ~ therapy + age
##   Res.Df  RSS Df Sum of Sq  F    Pr(>F)
## 1      197 30817
## 2      196 28351  1      2467 17.1 0.000054
```

```
anova(lm(response ~ age + therapy, data = d.cat2)) ## als sequentielle Anova

## Analysis of Variance Table
##
## Response: response
##           Df Sum Sq Mean Sq F value    Pr(>F)
## age         2  19964    9982    69.0 < 2e-16
## therapy     1   2467     2467    17.1 0.000054
## Residuals  196  28351      145
```

Sequentielle Tests: Reihenfolge beachten

Achtung, die Reihenfolge ist wichtig, **wenn man nur das grosse Modell eingibt** in `anova()`. Dazu das Modell ohne Interaktion (Haupteffektmodell) mit anderer Reihenfolge:

```
anova(lm(response ~ therapy + age, data = d.cat2)) ## Haupteffektmodell mit neuer Reihenfolge.
```

```
## Analysis of Variance Table
##
## Response: response
##          Df Sum Sq Mean Sq F value    Pr(>F)
## therapy    1   4117     4117    28.5 0.00000026
## age        2  18313     9157    63.3 < 2e-16
## Residuals 196  28351      145
```

- Nicht-kontrollierter Effekt von therapy
- Effekt von age, kontrolliert für therapy

Welche Residualvarianz?*

- Da der Interaktionseffekt nicht signifikant ist, sollten wir auch das Haupteffektmodell brauchen, um den für Alter kontrollierten Therapieeffekt zu testen.
- Bei Abwesenheit von Interaktion sollte die Varianz, die zum Interaktionseffekt gehört, dem Zufall zugeordnet werden.

Grösse des für age kontrollierten Effekts von therapy

- Der Therapieeffekt ist also unabhängig von der Altersgruppe.
- Das war auch im Interaktionsplot ersichtlich. Die Profile sind annähernd parallel.
- age bleibt aber vorerst im Modell als potentieller Confounder. Der für Alter kontrollierte Effekt von therapy (der über den Effekt von age hinausgehende Effekt) ist 7.109 (Punktschätzung):

```
summary(modelMain)$coef
```

| ## | Estimate | Std. Error | t value | Pr(> t) |
|----------------|----------|------------|---------|----------|
| ## (Intercept) | 34.62 | 2.27 | 15.26 | 3.73e-35 |
| ## therapyTrt | 7.11 | 1.72 | 4.13 | 5.38e-05 |
| ## ageyoung | 17.22 | 2.73 | 6.31 | 1.83e-09 |
| ## ageold | 27.39 | 2.49 | 10.98 | 3.55e-22 |

Nicht kontrollierter Effekt von therapy

- Der nicht für age kontrollierte Effekt von therapy ist 9.08 (Punktschätzung) und entspricht dem Unterschied der **gewichteten Durchschnitte** in Tabelle 1.
- Hier wird die Variable age in der Analyse ignoriert.

```
summary(modelTherapy)$coef
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    53.91      1.54    34.94 1.29e-86
## therapyTrt      9.08      2.17     4.18 4.38e-05
```

- was äquivalent wäre mit

```
t.test(response ~ therapy, var.equal = TRUE)
##
## Two Sample t-test
##
## data: response by therapy
## t = -4, df = 198, p-value = 0.00004
## alternative hypothesis: true difference in means between group Ctrl and group Trt is not equal to 0
## 95 percent confidence interval:
##  -13.36 -4.79
## sample estimates:
## mean in group Ctrl mean in group Trt
##           53.9           63.0
```

Kontraste

- Kontraste sind **Linearkombinationen von Parametern** mit der Bedingung, dass die Summe der Koeffizienten Null ist. Mit Konstanten a_1, a_2, \dots, a_t und Parametern $\theta_1, \theta_2, \dots, \theta_t$ ist ein Kontrast also

$$L = \sum_{i=1}^t a_i \theta_i, \quad \text{mit } \sum_{i=1}^t a_i = 0.$$

- Mit `emmeans()` kann man die Zwischengruppenunterschiede für alle Altersgruppen berechnen, jetzt aber mit Konfidenzintervallen und Tests.
- Bei Abwesenheit von Interaktionseffekten sind hier die Therapieeffekte für alle Altersgruppen gleich.

Treatment effect unadjusted

```
em <- emmeans(modelTherapy, revpairwise ~ therapy)
summary(em, infer = c(TRUE, TRUE)) ## damit mit CIs und p-werten
```

```
## $emmeans
##   therapy emmean   SE df lower.CL upper.CL t.ratio p.value
##   Ctrl      53.9 1.54 198    50.9     57 34.900 <.0001
##   Trt       63.0 1.53 198    60.0     66 41.200 <.0001
##
## Confidence level used: 0.95
##
## $contrasts
##   contrast estimate   SE df lower.CL upper.CL t.ratio p.value
##   Trt - Ctrl     9.08 2.17 198     4.79    13.4  4.180 <.0001
##
## Confidence level used: 0.95
```

Treatment effect adjusted for age

```
em <- emmeans(modelMain, revpairwise ~ therapy)
summary(em, infer = c(TRUE, TRUE)) ## damit mit CIs und p-werten
```

```
## $emmeans
##   therapy emmean   SE df lower.CL upper.CL t.ratio p.value
##   Ctrl      49.5 1.27 196      47      52.0 38.900 <.0001
##   Trt       56.6 1.33 196      54      59.2 42.500 <.0001
##
## Results are averaged over the levels of: age
## Confidence level used: 0.95
##
## $contrasts
##   contrast estimate   SE df lower.CL upper.CL t.ratio p.value
##   Trt - Ctrl      7.11 1.72 196      3.71      10.5  4.130 0.0001
##
## Results are averaged over the levels of: age
## Confidence level used: 0.95
```

Prinzip der Marginalität! (Note!)

```
em <- emmeans(modelInt, revpairwise ~ therapy)

## NOTE: Results may be misleading due to involvement in interactions

summary(em, infer = c(TRUE, TRUE)) ## damit mit CIs und p-werten

## $emmeans
##   therapy emmean   SE df lower.CL upper.CL t.ratio p.value
##   Ctrl      49.6 1.33 194    47.0    52.2  37.400 <.0001
##   Trt       56.4 1.54 194    53.4    59.5  36.500 <.0001
##
## Results are averaged over the levels of: age
## Confidence level used: 0.95
##
## $contrasts
##   contrast   estimate    SE df lower.CL upper.CL t.ratio p.value
##   Trt - Ctrl     6.83 2.04 194     2.81    10.8   3.350 0.0010
##
## Results are averaged over the levels of: age
## Confidence level used: 0.95
```

Zwischengruppenunterschiede pro Altersgruppe

```

em <- emmeans(modelInt, revpairwise ~ therapy | age)
summary(em, infer = c(TRUE, TRUE)) ## damit mit CIs und p-werten


## $emmeans
## age = child:
##   therapy emmean   SE df lower.CL upper.CL t.ratio p.value
##   Ctrl      34.9 2.70 194    29.6    40.2  12.900 <.0001
##   Trt       41.2 3.82 194    33.7    48.7  10.800 <.0001
##
## age = young:
##   therapy emmean   SE df lower.CL upper.CL t.ratio p.value
##   Ctrl     52.1 2.42 194    47.4    56.9  21.600 <.0001
##   Trt      58.7 2.07 194    54.6    62.8  28.300 <.0001
##
## age = old:
##   therapy emmean   SE df lower.CL upper.CL t.ratio p.value
##   Ctrl     61.8 1.64 194    58.5    65.0  37.600 <.0001
##   Trt      69.3 1.60 194    66.2    72.5  43.300 <.0001
##
## Confidence level used: 0.95
##
## $contrasts
## age = child:
##   contrast estimate   SE df lower.CL upper.CL t.ratio p.value
##   Trt - Ctrl     6.31 4.68 194   -2.918    15.6   1.350 0.1790
##
## age = young:
##   contrast estimate   SE df lower.CL upper.CL t.ratio p.value
##   Trt - Ctrl     6.60 3.18 194    0.321    12.9   2.070 0.0395
##
## age = old:
##   contrast estimate   SE df lower.CL upper.CL t.ratio p.value
##   Trt - Ctrl     7.56 2.30 194    3.038    12.1   3.300 0.0012
##
## Confidence level used: 0.95

```



Predictions*

```
prInt <- effects::predictorEffects(modelInt, partial.residuals = TRUE)
prMain <- effects::predictorEffects(modelMain, partial.residuals = TRUE)
# plot(prInt, lines=list(multiline=TRUE))
plot(prInt, partial.residual = list(pch = "*", col = "#FF00FF80"))
plot(prMain, partial.residual = list(pch = "*", col = "#FF00FF80"))
```


therapy predictor effect plot



age predictor effect plot



therapy predictor effect plot



age predictor effect plot

